Al Instruction: Nlu Training Guide

FATAPLUS - Plateforme Agricole Madagascar

Dernière mise à jour : 10/07/2025

FATAPLUS NLU Training Guide

№ Introduction au NLU (Natural Language Understanding)

Le NLU permet à FATAPLUS AI de comprendre les intentions des agriculteurs, extraire les entités importantes et adapter ses réponses selon le contexte conversationnel.

Objectifs NLU FATAPLUS

- 1. Classification d'Intentions : Identifier le type de demande (conseil, produit, formation, etc.)
- 2. Extraction d'Entités : Reconnaître cultures, régions, saisons, problèmes
- 3. Analyse de Sentiment : Détecter urgence, satisfaction, frustration
- 4. Gestion Contextuelle: Maintenir le contexte conversationnel

III Architecture NLU

Texte Utilisateur → Preprocessing → Intent Classification → Entity Extraction → Context Management → Structured Output

Classification d'Intentions

Intentions Principales

```
intentions_agricoles:
 conseil_technique:
   description: "Demande de conseil agricole"
     - "Comment planter du riz ?"
     - "Quand semer la vanille ?"
     - "Problème avec mes tomates"
 recherche_produit:
   description: "Recherche de produits/outils"
   exemples:
     - "Besoin de semences de maïs"
     - "Quel engrais pour le café ?"
     - "Outils pour irrigation"
 formation_cours:
   description: "Demande de formation"
   exemples:
     - "Cours sur l'agriculture bio"
```

- "Formation élevage poulets"- "Apprendre la permaculture"

```
probleme_maladie:
  description: "Problème phytosanitaire"
  exemples:
   - "Mes plants jaunissent"
    - "Insectes sur les feuilles"
   - "Maladie du riz"
information_marche:
  description: "Informations commerciales"
  exemples:
    - "Prix du girofle"
    - "Où vendre ma récolte ?"
    - "Demande pour la vanille"
meteo_saison:
  description: "Informations météo/saisonnières"
  exemples:
    - "Quand planter avant les pluies ?"
    - "Saison sèche à Antananarivo"
    - "Préparer pour cyclone"
```

Intentions Secondaires

```
intentions_support:
    salutation:
        exemples: ["Bonjour", "Salut", "Bonsoir"]

remerciement:
    exemples: ["Merci", "Merci beaucoup", "Misaotra"]

demande_aide:
    exemples: ["Aidez-moi", "Je ne comprends pas", "Expliquez"]

feedback:
    exemples: ["Très utile", "Ça marche", "Pas satisfait"]
```

Extraction d'Entités

Entités Agricoles

```
entites_principales:
 cultures:
   type: "liste_fermee"
      cereales: ["riz", "maïs", "blé", "orge"]
      legumineuses: ["haricot", "pois", "lentille", "arachide"]
      tubercules: ["manioc", "patate", "pomme_terre", "igname"]
      epices: ["vanille", "girofle", "cannelle", "poivre"]
      fruits: ["litchi", "mangue", "banane", "ananas"]
      legumes: ["tomate", "oignon", "carotte", "salade"]
  regions:
    type: "liste_fermee"
    valeurs:
      provinces:
        [
          "Antananarivo",
          "Fianarantsoa",
          "Toamasina",
          "Mahajanga",
          "Toliara",
          "Antsiranana",
        ]
```

```
villes: ["Antsirabe", "Sambava", "Morondava", "Tamatave"]
  saisons:
    type: "liste_fermee"
    valeurs: ["saison_seche", "saison_pluies", "inter_saison"]
    type: "expression_reguliere"
    patterns:
      maladies: ["maladie", "champignon", "virus", "bacterie"]
      ravageurs: ["insecte", "criquet", "chenille", "puceron"]
      climatiques: ["secheresse", "inondation", "grele", "cyclone"]
  quantites:
    type: "numerique"
    patterns: ["\\d+\\s*(kg|tonne|hectare|m2|litre)"]
  dates:
    type: "temporel"
    patterns: ["mois", "semaine", "janvier|fevrier|...", "demain|hier"]
Entités Contextuelles
entites_contexte:
 niveau_experience:
   valeurs: ["debutant", "intermediaire", "expert", "nouveau"]
 urgence:
   indicateurs: ["urgent", "rapidement", "maintenant", "vite"]
    indicateurs: ["pas_cher", "economique", "budget_limite", "gratuit"]
  preferences:
    bio: ["bio", "biologique", "naturel", "sans_chimique"]
    moderne: ["moderne", "technologique", "innovant", "nouveau"]
```

Modèles d'Entraînement

1. Classification d'Intentions

```
# Configuration modèle classification
intent_model_config = {
    "architecture": "transformer",
    "model_base": "xlm-roberta-base", # Support multilingue
    "fine_tuning": {
        "learning rate": 2e-5,
       "batch size": 16,
        "epochs": 5.
        "warmup_steps": 100
    },
    "data_augmentation": {
        "paraphrasing": True,
        "back_translation": ["en", "mg"], # Français ↔ Anglais ↔ Malagasy
        "synonym_replacement": True
   }
}
```

2. Extraction d'Entités (NER)

```
# Configuration NER
ner_model_config = {
```

Données d'Entraînement

1. Collecte de Données

```
# Sources de données pour entraînement
data_sources = {
    "conversations_existantes": \{
       "source": "logs_fataplus",
        "volume": "10000_conversations",
        "qualite": "reel_utilisateur"
    "donnees_synthetiques": \{
        "generation": "templates_variations",
        "volume": "50000_exemples",
        "qualite": "controlee"
    "experts_agricoles": {
        "source": "interviews_specialistes",
        "volume": "2000_qa_pairs",
        "qualite": "tres_haute"
    "forums_agricoles": {
        "source": "web_scraping",
        "volume": "20000_posts",
        "qualite": "variable"
```

2. Annotation des Données

```
# Schéma d'annotation
annotation_schema = {
    "format": "IOB2",  # Inside-Outside-Begin
    "outils": ["Label Studio", "Prodigy", "Doccano"],
    "guidelines": {
        "cultures": "Annoter nom complet (ex: 'riz rouge' pas juste 'riz')",
        "regions": "Inclure villages/districts si mentionnés",
        "problemes": "Capturer symptômes et causes",
        "quantites": "Inclure unité de mesure"
    },
    "qualite": {
        "inter_annotator_agreement": "> 0.85",
        "double_annotation": "20% des données",
        "expert_validation": "100% échantillon test"
    }
}
```

Pipeline d'Entraînement

1. Preprocessing

```
# Étapes de préparation
preprocessing_steps = {
    "nettoyage": {
        "normalisation_unicode": True,
        "suppression_caracteres_speciaux": False, # Garder accents
        "correction_orthographe": True,
        "detection_langue": True
    },
    "tokenisation": {
        "tokenizer": "xlm-roberta-tokenizer",
        "max_length": 512,
        "padding": "max_length",
        "truncation": True
    },
    "augmentation": {
        "paraphrase_generation": True,
        "noise_injection": 0.1,
        "entity_replacement": True
    }
}
```

2. Entraînement Multi-tâches

```
# Configuration multi-task learning
multitask_config = {
    "taches": {
        "intent_classification": {
            "poids": 0.4,
            "metrique": "f1_weighted"
        },
        "entity_extraction": {
            "poids": 0.4,
            "metrique": "f1_entity"
       },
        "sentiment_analysis": {
            "poids": 0.2,
            "metrique": "accuracy"
        }
    "partage_representations": True,
    "optimisation_jointe": True
```

Adaptation Multilingue

1. Support Français-Malagasy

```
# Configuration multilingue
multilingual_config = {
    "langues_principales": ["fr", "mg"],
    "detection_langue": {
        "automatique": True,
        "fallback": "fr",
        "confiance_minimum": 0.7
    },
    "traduction": {
        "service": "google_translate_api",
        "cache": True,
        "post_processing": "correction_agricole"
    },
    "vocabulaire_mixte": {
```

```
"termes_malagasy": "conserver_original",
    "expressions_locales": "annoter_traduction",
    "code_switching": "gerer_automatiquement"
}
```

2. Dictionnaire Agricole Bilingue

```
# Dictionnaire spécialisé
agricultural_dictionary = {
    "cultures": {
        "vary": {"fr": "riz", "context": "cereale_base"},
        "katsaka": {"fr": "maïs", "context": "cereale_secondaire"},
        "mangahazo": {"fr": "manioc", "context": "tubercule"},
        "voatavo": {"fr": "courge", "context": "legume_fruit"}
},
    "techniques": {
        "fambolena": {"fr": "culture", "context": "technique_generale"},
        "famafazana": {"fr": "semis", "context": "technique_semis"},
        "fanondrahana": {"fr": "irrigation", "context": "technique_eau"}
}
```

il Évaluation et Métriques

1. Métriques par Tâche

```
evaluation_metrics = {
    "intent_classification": {
       "accuracy": "precision_globale",
        "f1_weighted": "f1_pondere_classes",
        "confusion_matrix": "analyse_erreurs",
        "per_class_metrics": "performance_par_intention"
    "entity_extraction": {
       "f1_entity": "f1_niveau_entite",
        "precision_recall": "par_type_entite",
        "exact_match": "correspondance_exacte",
        "partial_match": "correspondance_partielle"
    },
    "overall_pipeline": {
        "end_to_end_accuracy": "precision_complete",
        "response_relevance": "pertinence_reponse",
        "user_satisfaction": "satisfaction_utilisateur"
}
```

2. Tests A/B

```
"duree": "2_semaines",
  "trafic_split": "50/50",
  "critere_succes": "amelioration_5_percent"
```

Néploiement et Monitoring

1. Pipeline de Production

```
production_pipeline = {
    "preprocessing": {
        "latence_max": "50ms",
        "cache_tokenization": True
    },
    "inference": {
        "batch_processing": True,
        "gpu_acceleration": True,
        "model_quantization": "int8"
    },
    "post_processing": {
        "confidence_filtering": 0.7,
        "entity_validation": True,
        "response_formatting": True
    }
}
```

2. Monitoring Continu

```
monitoring_nlu = {
    "metriques_temps_reel": {
         "latence_inference": "< 100ms",
         "accuracy_drift": "detection_degradation",
         "distribution_intentions": "monitoring_shift",
         "nouvelles_entites": "detection_automatique"
    },
    "alertes": {
        "accuracy_drop": "< 85%",
         "high_latency": "> 200ms",
         "unknown_intents": "> 10%",
         "entity_extraction_fail": "> 15%"
    },
    "retraining_triggers": {
        "performance_degradation": True,
        "new_data_volume": "1000_new_samples",
        "domain_shift": True
    }
}
```

Amélioration Continue

1. Active Learning

```
active_learning_config = {
    "strategies": {
        "uncertainty_sampling": "echantillons_incertains",
        "diversity_sampling": "echantillons_diversifies",
        "query_by_committee": "desaccord_modeles"
    },
    "annotation_budget": "100_samples_per_week",
    "retraining_frequency": "monthly",
```

```
"human_in_the_loop": True
}
```

2. Feedback Loop

```
feedback_integration = {
    "sources": {
       "user_corrections": "corrections_utilisateur",
       "expert_validation": "validation_experts",
       "conversation_outcomes": "succes_conversations"
    },
    "processing": {
       "confidence_weighting": True,
       "consensus_requirement": "2_experts_minimum",
        "automated_validation": "rules_based"
    },
    "integration": {
       "training_data_update": "automatic",
       "model_retraining": "scheduled",
       "a_b_testing": "continuous"
}
```

Version: 1.0

Dernière mise à jour : Décembre 2024

Prochaine révision : Mars 2025

Guide complet pour développer un système NLU de pointe pour l'assistance agricole FATAPLUS, adapté au contexte malgache et multilingue.

FATAPLUS - Plateforme Agricole Numérique Madagascar

Contact: contact@fata.plus | Web: https://fata.plus

Document généré le 10/07/2025 à 09:49:58